Pareamento

João Felix

24-09-2025

Contents

Introdução

O conjunto de códigos abaixo replica o Capítulo 8, intitulado **"Pareamento"**, do livro *Avaliação de Impacto na Prática*, segunda edição, de Paul J. Gertler, Sebastián Martínez, Patrick Premand, Laura B. Rawlings e Christel M. J. Vermeersch. Este capítulo trata da avaliação de impacto utilizando métodos de pareamento, em especial o **Propensity Score Matching (PSM)**. Essa técnica busca comparar beneficiários de um programa com não beneficiários que possuem características observáveis semelhantes, reduzindo o viés de seleção. A replicação foi realizada em **R**, utilizando os pacotes `MatchIt` e `estimatr` para estimar os escores de propensão, realizar o pareamento e aplicar regressões robustas, permitindo reproduzir os resultados apresentados no livro *Avaliação de Impacto na Prática*.

O código utilizado segue de perto aquele disponível em *Impact Evaluation in Practice Solutions for Second Edition in R*, desenvolvido pelo professor **Liam F. Beiser-McGrath**, com pequenas adaptações. Esse material pode ser acessado no site *Impact Evaluation in Practice Solutions for Second Edition in R*.

.

Bibliotecas

```r
# Importação
library(haven) # Stata

# Manipulação
library(dplyr)
library(tidyr)

# Pareamento
library(MatchIt) # PSM

# Regressões
library(estimatr)

# Visualização e tabelas
library(ggplot2)
library(kableExtra)
```

Importando e manipulando os dados

```r
# Importand os dados
dados <- read_dta('dados/evaluation.dta')
# head(dados, 5)
```

Colocando os dados em formato wide. Cada domicílio ocupa várias linhas, com variáveis medidas antes e depois da inscrição. Para fazer o pareamento, cada linha deve representar um domicílio único, criando colunas separadas para as características de cada período.

```
dados_wide <- dados %>%
  pivot_wider(
    names_from = round,
    values_from = c(
      health_expenditures, poverty_index, age_hh, age_sp,
      educ_hh, educ_sp, female_hh, indigenous, hhsize,
      dirtfloor, bathroom, land, hospital_distance, hospital
    )
  ) %>%
  filter(!is.na(health_expenditures_0))
```

Escore de propensão nos dois cenários

No primeiro cenário o pareamento, por meio de propensity score, será feito utilizando um conjunto maior de variáveis para prever a inscrição no programa, incluindo atributos socioeconômicos das famílias. No segundo cenário, há pouca informação para prever a inscrição (apenas o nível educacional e a idade do chefe de família)

Quando se fala em estimar o escore de propensão, na verdade está se referindo ao cálculo da probabilidade de cada unidade (como um domicílio ou indivíduo) receber o tratamento com base em suas características observáveis. Esse cálculo combina várias covariáveis em um único valor, chamado escore de propensão, que reflete quão semelhante cada unidade é às outras em termos de probabilidade de tratamento. Com esse escore, podemos parear unidades tratadas e não tratadas com probabilidades semelhantes, permitindo comparações mais justas e reduzindo vieses causados por diferenças nas características iniciais. Os dois blocos de código abaixo fazen isso para os dois cenários citados.

Escore de propensão com menor número de variáveis Abaixo estima-se a probabilidade de cada família se inscrever no programa (o escore de propensão) com um menor número de atributos.

```
set.seed(100)  # define a semente aleatória

# Estimando o score de propensão com o conjunto limitado de variáveis
psm_r <- matchit(
  enrolled ~ age_hh_0 + educ_hh_0,
  data = dados_wide %>% dplyr::select(-hospital_0, -hospital_1),
  distance = "glm",
  link = "probit"
)
```

Os valores abaixo indicam que, quanto maior a idade e a educação do chefe da família na linha de base, menor é a probabilidade de participar do programa. O que o modelo probit mostra é apenas a direção do efeito. Todas as variáveis são significativas estatisticamente.

```
# Coeficientes do modelo limitado
coef_r <- summary(psm_r$model)$coefficients
print(coef_r, digits = 2)
```

```
##             Estimate Std. Error z value Pr(>|z|)
## (Intercept)    0.554     0.0581     9.5  1.6e-21
## age_hh_0      -0.021     0.0011   -20.3  7.9e-92
## educ_hh_0     -0.041     0.0056    -7.2  5.2e-13
```

Escore de propensão com mais variáveis Abaixo, estima-se a probabilidade de cada família se inscrever no programa (o escore de propensão) com um maior número de variáveis.

```r
set.seed(100)

# Estimando o score de propensão com o conjunto maior de variáveis
psm_ur <- matchit(
  enrolled ~ age_hh_0 + educ_hh_0 + age_sp_0 + educ_sp_0 +
             female_hh_0 + indigenous_0 + hhsize_0 + dirtfloor_0 +
             bathroom_0 + land_0 + hospital_distance_0,
  data = dados_wide %>% dplyr::select(-hospital_0, -hospital_1),
  distance = "glm",
  link = "probit"
)
```

A probabilidade de uma família se inscrever no programa diminui quando seus membros são mais velhos, possuem maior nível de instrução, a família é chefiada por uma mulher, a residência possui banheiro ou a propriedade possui maiores áreas de terra. Por outro lado, a probabilidade aumenta se a família for indígena, tiver mais integrantes, residir em uma casa com piso de terra ou estiver situada longe de um hospital.

```r
# Coeficientes do modelo completo
coef_ur <- summary(psm_ur$model)$coefficients
print(coef_ur, digits = 2)
```

```
##                     Estimate Std. Error z value Pr(>|z|)
## (Intercept)          -0.4975    0.09044    -5.5  3.8e-08
## age_hh_0             -0.0131    0.00177    -7.4  1.2e-13
## educ_hh_0            -0.0215    0.00622    -3.5  5.5e-04
## age_sp_0             -0.0079    0.00206    -3.8  1.3e-04
## educ_sp_0            -0.0155    0.00672    -2.3  2.1e-02
## female_hh_0          -0.0205    0.05180    -0.4  6.9e-01
## indigenous_0          0.1614    0.03131     5.2  2.6e-07
## hhsize_0              0.1189    0.00667    17.8  4.7e-71
## dirtfloor_0           0.3759    0.03084    12.2  3.6e-34
## bathroom_0           -0.1245    0.02904    -4.3  1.8e-05
## land_0               -0.0278    0.00503    -5.5  3.5e-08
## hospital_distance_0   0.0016    0.00035     4.5  6.9e-06
```

Assim, de modo geral, parece que as famílias mais pobres e com menor escolaridade têm maior tendência a se inscrever, o que é positivo para um programa voltado ao público de baixa renda.

Suporte comum O gráfico mostra as distribuições do escore de propensão para famílias inscritas (linha preta sólida) e não inscritas (linha vermelha tracejada). A linha preta representa as famílias que participaram do programa, enquanto a vermelha indica as famílias que não participaram.

```r
# Adiciona a coluna do escore de propensão
dados_wide <- dados_wide %>%
  mutate(ps_ur = psm_ur$model$fitted.values,
         enrolled_lab = ifelse(enrolled == 1, "Inscrito", "Nao inscrito"))

# Plot simples com linha tracejada para não inscrito
ggplot(dados_wide, aes(x = ps_ur, color = enrolled_lab, linetype = enrolled_lab)) +
  geom_density(size = 1) +
  xlab("Escore de Propensao") +
  ylab("Densidade") +
  scale_color_manual(values = c("Nao inscrito" = "red", "Inscrito" = "black")) +
```

```r
  scale_linetype_manual(values = c("Nao inscrito" = "dashed", "Inscrito" = "solid")) +
  theme_minimal() +
  theme(legend.position = "top",
        legend.title = element_blank())
```

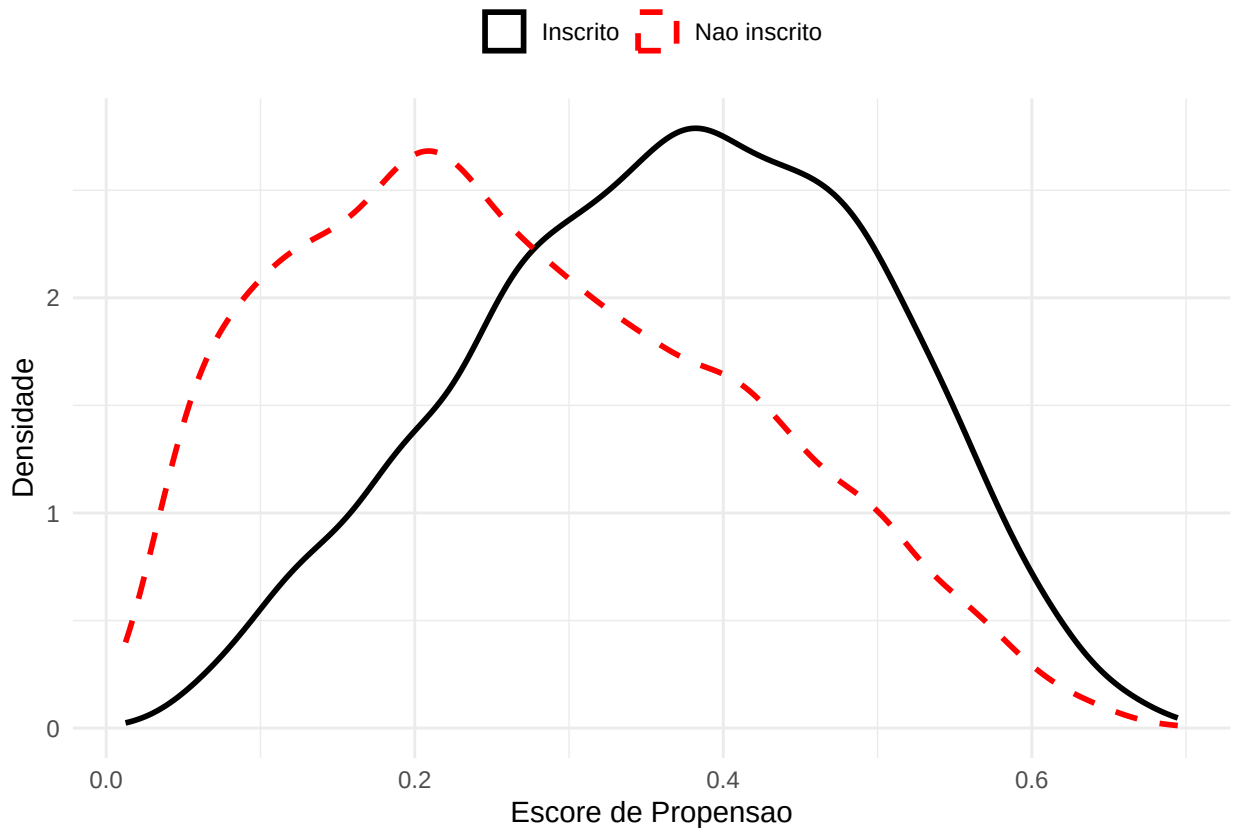

A área onde as duas linhas se sobrepõem corresponde ao suporte comum, ou seja, o intervalo de escores em que existem famílias tanto tratadas quanto de controle com probabilidades semelhantes de participação. Essa sobreposição é essencial, pois indica que é possível comparar famílias dos dois grupos de forma justa, reduzindo vieses.

Diferenças entre as linhas fora da sobreposição mostram regiões onde as probabilidades de inscrição diferem muito entre os grupos, ou seja, onde não há famílias comparáveis. Quanto maior a sobreposição, mais confiável é a análise do efeito do programa, pois existem unidades tratadas e de controle similares para o pareamento.

Abaixo, temos como se comportam as variáveis antes do paraeamento.

```r
kable(summary(psm_ur)$sum.all,
      caption = "Balanceamento antes do pareamento") %>%
  kable_styling()
```

Table 1: Balanceamento antes do pareamento

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio	eCDF Mean	eCDF Max	Std
distance	0.3694119	0.2683525	0.7780852	0.8189848	0.2003240	0.3118783	
age_hh_0	41.6565796	48.1384372	-0.4731180	0.7797904	0.0881294	0.2074113	
educ_hh_0	2.9711803	2.7744736	0.0742925	0.8959873	0.0218441	0.0622731	
age_sp_0	36.8363698	41.6117427	-0.4098452	0.8042407	0.0647834	0.2100395	

educ_sp_0	2.7032726	2.5810189	0.0494165	0.9256881	0.0141252	0.0689847
female_hh_0	0.0732119	0.1100878	-0.1415669	NA	0.0368759	0.0368759
indigenous_0	0.4291498	0.3203339	0.2198503	NA	0.1088159	0.1088159
hhsize_0	5.7699055	4.9263203	0.4225943	0.8029708	0.0651539	0.1833283
dirtfloor_0	0.7216599	0.5533170	0.3756130	NA	0.1683429	0.1683429
bathroom_0	0.5735493	0.6340481	-0.1223283	NA	0.0604988	0.0604988
land_0	1.6771255	2.2511153	-0.2172044	0.6390513	0.0240692	0.0881821
hospital_distance_0	109.2043122	103.6626222	0.1323667	0.9916816	0.0395806	0.0829805

Abaixo, temos como se comportam as variáveis antes do paraeamento.

```
kable(summary(psm_ur)$sum.matched,
      caption = "Balanceamento após o pareamento") %>%
  kable_styling()
```

Table 2: Balanceamento após o pareamento

	Means Treated	Means Control	Std. Mean Diff.	Var. Ratio	eCDF Mean	eCDF Max	Std
distance	0.3694119	0.3687162	0.0053561	1.0138523	0.0007394	0.0084345	
age_hh_0	41.6565796	41.7867746	-0.0095031	1.0867281	0.0114843	0.0381242	
educ_hh_0	2.9711803	2.9549320	0.0061367	0.9271782	0.0094467	0.0239541	
age_sp_0	36.8363698	36.9915655	-0.0133196	1.1143952	0.0104041	0.0371120	
educ_sp_0	2.7032726	2.7128880	-0.0038867	0.8918377	0.0072981	0.0215924	
female_hh_0	0.0732119	0.0732119	0.0000000	NA	0.0000000	0.0000000	
indigenous_0	0.4291498	0.4234143	0.0115879	NA	0.0057355	0.0057355	
hhsize_0	5.7699055	5.7884615	-0.0092956	0.8691665	0.0105626	0.0229420	
dirtfloor_0	0.7216599	0.7253711	-0.0082806	NA	0.0037112	0.0037112	
bathroom_0	0.5735493	0.5732119	0.0006822	NA	0.0003374	0.0003374	
land_0	1.6771255	1.7010796	-0.0090645	1.0159498	0.0045968	0.0276653	
hospital_distance_0	109.2043122	108.5100383	0.0165832	0.9993878	0.0104486	0.0485830	

Estimando o impacto usando o método de pareamento

O quadro apresenta os resultados do pareamento por escore de propensão para o gasto com saúde das famílias, comparando os inscritos no programa com famílias não inscritas, usando dois conjuntos de covariáveis: completo e limitado. A média do gasto das famílias inscritas é de aproximadamente 7,84 US$, enquanto a média das famílias de comparação pareada é de 17,84 US$ quando se usa o conjunto completo e de 19,00 US$ com o conjunto limitado.

```
set.seed(100)

# --- Conjunto completo ---
matched_ur <- match.data(psm_ur)

impactos_ur <- matched_ur %>%
  group_by(subclass) %>%
  summarize(
    tratado = health_expenditures_1[enrolled == 1],
    controle = health_expenditures_1[enrolled == 0],
    impacto = tratado - controle
  )
```

```r
# Médias e diferença
media_tratado_ur <- mean(impactos_ur$tratado)
media_controle_ur <- mean(impactos_ur$controle)
dif_ur <- mean(impactos_ur$impacto)

# --- Conjunto limitado ---
matched_r <- match.data(psm_r)

impactos_r <- matched_r %>%
  group_by(subclass) %>%
  summarize(
    tratado = health_expenditures_1[enrolled == 1],
    controle = health_expenditures_1[enrolled == 0],
    impacto = tratado - controle
  )

# Médias e diferença
media_tratado_r <- mean(impactos_r$tratado)
media_controle_r <- mean(impactos_r$controle)
dif_r <- mean(impactos_r$impacto)

# --- Montar quadro final ---
quadro <- data.frame(
  Conjunto = c("Completo", "Limitado"),
  Inscritos = c(media_tratado_ur, media_tratado_r),
  Comparacao_Pareada = c(media_controle_ur, media_controle_r),
  Diferenca = c(dif_ur, dif_r)
)

quadro
```

```
##   Conjunto Inscritos Comparacao_Pareada Diferenca
## 1 Completo  7.839773           17.84038 -10.00061
## 2 Limitado  7.839773           19.00249 -11.16272
```

A diferença entre inscritos e comparação pareada, que representa o efeito estimado do programa, é negativa em ambos os casos (-10,00 US$ no conjunto completo e -11,16 US$ no conjunto limitado), indicando que a participação no programa está associada a uma redução nos gastos com saúde. A inclusão de mais covariáveis no conjunto completo ajusta melhor a comparação, reduzindo ligeiramente a magnitude da diferença, mas a direção do efeito permanece consistente.

Avaliação por meio da regressão linear

O resultado da regressão robusta ponderada mostra que, usando o conjunto limitado de variáveis para pareamento, as famílias inscritas no programa gastaram, em média, 11,16 US$ a menos em saúde do que famílias semelhantes não inscritas. O intercepto indica que as famílias de comparação pareadas gastam cerca de 19,00 US$. O efeito negativo de enrolled é altamente significativo e o intervalo de confiança sugere que essa redução é precisa e não fruto do acaso. Em resumo, a participação no programa está associada a uma redução consistente e estatisticamente significativa nos gastos com saúde.

```r
# Regressão robusta no conjunto limitado
out_lm_r <- lm_robust(
  health_expenditures_1 ~ enrolled,
  data = matched_r,
  clusters = locality_identifier,
```

```r
  weights = weights
)

summary(out_lm_r)
```

```
##
## Call:
## lm_robust(formula = health_expenditures_1 ~ enrolled, data = matched_r,
##     weights = weights, clusters = locality_identifier)
##
## Weighted, Standard error type:  CR2
##
## Coefficients:
##             Estimate Std. Error t value  Pr(>|t|) CI Lower CI Upper     DF
## (Intercept)    19.00     0.3012   63.08 3.786e-62    18.40     19.6  68.11
## enrolled      -11.16     0.3836  -29.10 3.142e-52   -11.92    -10.4 105.54
##
## Multiple R-squared:    0.3 , Adjusted R-squared:  0.2999
## F-statistic: 846.8 on 1 and 197 DF,  p-value: < 2.2e-16
```

O resultado da regressão robusta ponderada para o conjunto completo de variáveis mostra que as famílias inscritas no programa gastaram, em média, 10,00 US$ a menos em saúde do que famílias semelhantes não inscritas. O intercepto indica que as famílias de comparação pareadas gastam cerca de 17,84 US$. O coeficiente negativo de enrolled é altamente significativo, com intervalo de confiança de -10,73 a -9,27 US$, indicando que a redução nos gastos com saúde associada à participação no programa é consistente e não ocorre por acaso. Em resumo, a participação no programa está associada a uma redução significativa e precisa nos gastos com saúde, mesmo quando se considera um conjunto mais amplo de características de linha de base.

```r
# Regressão robusta no conjunto completo
out_lm_ur <- lm_robust(
  health_expenditures_1 ~ enrolled,
  data = matched_ur,
  clusters = locality_identifier,
  weights = weights
)

summary(out_lm_ur)
```

```
##
## Call:
## lm_robust(formula = health_expenditures_1 ~ enrolled, data = matched_ur,
##     weights = weights, clusters = locality_identifier)
##
## Weighted, Standard error type:  CR2
##
## Coefficients:
##             Estimate Std. Error t value  Pr(>|t|) CI Lower CI Upper     DF
## (Intercept)    17.84     0.2858   62.42 5.045e-65    17.27   18.410  72.89
## enrolled      -10.00     0.3690  -27.10 3.097e-49   -10.73   -9.269 105.11
##
## Multiple R-squared:  0.2797 ,    Adjusted R-squared:  0.2796
## F-statistic: 734.5 on 1 and 196 DF,  p-value: < 2.2e-16
```

Avaliando por meio de diferenças em diferenças

A regressão de diferença em diferenças ponderada pelo escore de propensão, utilizando o conjunto limitado de covariáveis, mostra que o gasto médio com saúde das famílias inscritas no programa aumentou em aproximadamente 3,07 unidades desde a linha de base. Esse resultado reflete a variação temporal nos gastos das famílias participantes, controlando pelas características observadas no início do período e ajustando os pesos do pareamento.

O coeficiente estimado para a variável enrolled foi de -9,72, estatisticamente significativo ao nível de 1%. Isso indica que, em média, a participação no programa está associada a uma redução de cerca de 9,72 unidades no aumento dos gastos de saúde das famílias em comparação com as não inscritas. O resultado é robusto e sugere que o programa exerceu um efeito relevante e consistente na redução dos gastos com saúde das famílias participantes.

```r
#  Preparar os dados longos com pesos do pareamento
df_long_match_r <- dados_wide %>%
  left_join(matched_r %>% dplyr::select(household_identifier, weights),
            by = "household_identifier") %>%
  filter(!is.na(weights))

# Criar a variável de diferença para DID
df_long_match_r <- df_long_match_r %>%
  mutate(diff = health_expenditures_1 - health_expenditures_0)

# Rodar o DID ponderado
did_reg_r <- lm_robust(
  diff ~ enrolled,
  data = df_long_match_r,
  weights = weights,
  clusters = locality_identifier
)

summary(did_reg_r)
```

```
##
## Call:
## lm_robust(formula = diff ~ enrolled, data = df_long_match_r,
##     weights = weights, clusters = locality_identifier)
##
## Weighted, Standard error type:  CR2
##
## Coefficients:
##             Estimate Std. Error t value  Pr(>|t|) CI Lower CI Upper     DF
## (Intercept)    3.071     0.2358   13.02 3.702e-20     2.60    3.541  68.11
## enrolled      -9.721     0.3015  -32.24 1.892e-56   -10.32   -9.123 105.54
##
## Multiple R-squared:  0.284 , Adjusted R-squared:  0.2838
## F-statistic:  1039 on 1 and 197 DF,  p-value: < 2.2e-16
```

A regressão de diferença em diferenças ponderada pelo escore de propensão, utilizando o conjunto completo de covariáveis, indica que os gastos médios com saúde das famílias inscritas no programa aumentaram em aproximadamente 2,81 unidades desde a linha de base. Esse resultado reflete a variação temporal nos gastos das famílias participantes após o pareamento, garantindo que as comparações sejam feitas entre grupos mais similares em termos de suas características observáveis iniciais.

O coeficiente estimado para a variável enrolled foi de -9,46, altamente significativo ao nível de 1%. Isso significa que a participação no programa está associada a uma redução de cerca de 9,46 unidades no aumento

dos gastos de saúde das famílias em comparação com as não inscritas. A magnitude e a significância estatística do efeito confirmam que o programa teve um impacto substancial na diminuição dos custos de saúde, mesmo quando se considera um conjunto mais amplo de variáveis de controle.

```r
# Preparar os dados longos com pesos do pareamento (conjunto completo)
df_long_match_ur <- dados_wide %>%
  left_join(matched_ur %>% dplyr::select(household_identifier, weights),
            by = "household_identifier") %>%
  filter(!is.na(weights))

# Criar a variável de diferença para DID
df_long_match_ur <- df_long_match_ur %>%
  mutate(diff = health_expenditures_1 - health_expenditures_0)

# Rodar o DID ponderado
did_reg_ur <- lm_robust(
  diff ~ enrolled,
  data = df_long_match_ur,
  weights = weights,
  clusters = locality_identifier
)

summary(did_reg_ur)
```

```
##
## Call:
## lm_robust(formula = diff ~ enrolled, data = df_long_match_ur,
##     weights = weights, clusters = locality_identifier)
##
## Weighted, Standard error type:  CR2
##
## Coefficients:
##             Estimate Std. Error t value  Pr(>|t|) CI Lower CI Upper     DF
## (Intercept)    2.806     0.2267   12.38 1.364e-19    2.354    3.258  72.89
## enrolled      -9.456     0.2977  -31.77 1.066e-55  -10.046   -8.866 105.11
##
## Multiple R-squared:  0.2934 ,    Adjusted R-squared:  0.2933
## F-statistic:  1009 on 1 and 196 DF,  p-value: < 2.2e-16
```