controle_sintético - proposição 99

04-03-2026

Contents

Introdução

Este documento apresenta a replicação do artigo **"Synthetic Control Methods for Comparative Case Studies: Estimating the Effect of California's Tobacco Control Program"**. O estudo de Abadie, Diamond e Hainmueller analisa os efeitos da Proposição 99, um amplo programa de controle do tabaco implementado na Califórnia em 1988, utilizando o método de controle sintético. Os autores demonstram que, após a adoção da medida, o consumo de cigarros no estado caiu de forma significativa em relação a uma região sintética de comparação. As estimativas indicam que, no ano de 2000, as vendas anuais per capita de cigarros na Califórnia foram aproximadamente 26 maços menores do que seriam na ausência da Proposição 99.

Bibliotecas

```r
library(dplyr)
library(ggplot2)
library(Synth)
library(tidyr)
```

Importando e manipulando os dados

Abaixo, importam-se os dados.

Visualizar as primeiras observações

```r
# Importando os dados
df <- read.csv("df_prop99.csv")

head(df, 5)
```

```
##   state state_name year cigsale lnincome beer age15to24 retprice
## 1     1    Alabama 1970    89.8       NA   NA 0.1788618     39.6
## 2     1    Alabama 1971    95.4       NA   NA 0.1799278     42.7
## 3     1    Alabama 1972   101.1 9.498476   NA 0.1809939     42.3
## 4     1    Alabama 1973   102.9 9.550107   NA 0.1820599     42.1
## 5     1    Alabama 1974   108.2 9.537163   NA 0.1831260     43.1
```

Evolução das vendas de cigarros (per capta) nas califórnia real e sintética

Para a plotar a figura 1 do artigo temos que calcular as médias de vendas de cigarro per capital dos Estados Unidos (excluindo a Califórnia) e comparar com a própria Califórnia.

```r
# Calcular média das vendas per capita dos EUA (excluindo Califórnia)
df_media <- df %>%
  group_by(year) %>%
```

```r
  summarise(
    california = mean(cigsale[state == 3]),    # Califórnia = state==3 no dataset
    rest_us = mean(cigsale[state != 3])        # média dos demais estados
  )
```

Como é argumentado no artigo, a figura mostra que utilizar o resto dos Estados Unidos como contrafactual não parece ser o mais adequado. Na figura abaixo, a linha vertical tracejada preta indica o ano de 1988, ano em que a proposição 99 foi aprovada.

```r
# Plotar figura
ggplot(df_media, aes(x = year)) +
  geom_line(aes(y = california, color = "California"), size = 1.0) +
  geom_line(aes(y = rest_us, color = "Resto dos EUA"), size = 1.0, linetype = "dashed") +
  geom_vline(xintercept = 1988, size=1.0, linetype = "dotted") + # ano da intervenção
  labs(
    title = "Tendencia na venda de Cigarros per capita",
    subtitle = "California vs. Resto dos Estados Unidos",
    x = "Ano", y = "Cigarros per capita",
    color = ""
  ) +
  theme_minimal(base_size = 14) +
  theme(legend.position = "bottom")
```

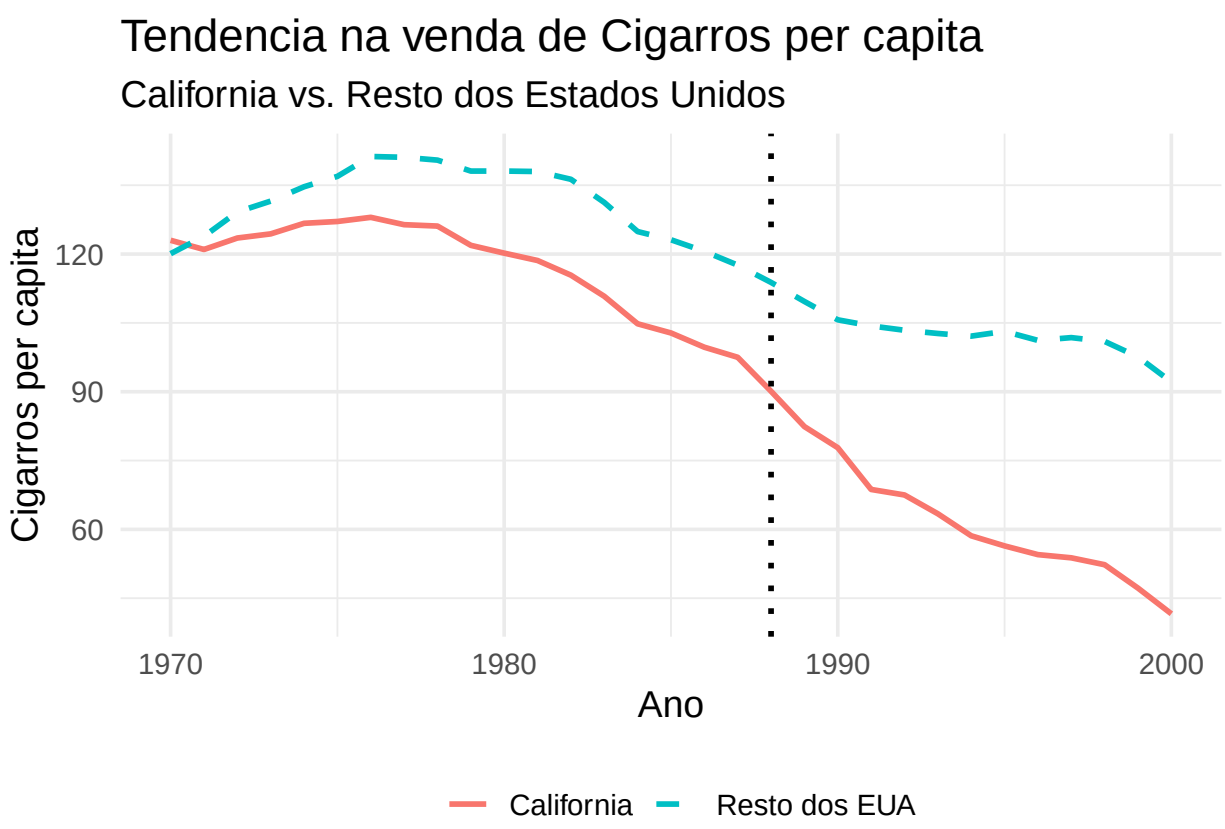

Médias dos preditores (variáveis independentes) das vendas de cigarros per capita

Como dito pelos autores "Para avaliar o efeito da Proposição 99 sobre o consumo de cigarros na Califórnia, a questão central é como o consumo de cigarros teria evoluído na Califórnia após 1988 na ausência da Proposição

99. O método de controle sintético fornece uma forma sistemática de estimar esse contrafactual."

Os autores continuam explicando que "é construido a Califórnia sintética como a combinação convexa dos estados do conjunto doador que mais se assemelhavam à Califórnia em termos dos valores pré-Proposição 99 dos preditores da prevalência do tabagismo."

Abaixo preparamos os dados para que possamos criar a unidade de tratamento sintética.

```
dataprep_out <- dataprep(
  foo = df,
  predictors = c("lnincome", "age15to24", "retprice"),
  special.predictors = list(
    list("beer", 1984:1988, c("mean")),           # beer média 1984-1988
    list("cigsale", 1975, c("mean")),
    list("cigsale", 1980, c("mean")),
    list("cigsale", 1988, c("mean"))
  ),
  dependent = "cigsale",
  unit.variable = "state",
  time.variable = "year",
  treatment.identifier = "California",
  controls.identifier = unique(df$state_name[-which(df$state_name == "California")]),
  time.predictors.prior = 1980:1988,             # médias das preditoras de 1980-1988
  time.optimize.ssr = 1970:1988,
  time.plot = 1970:2000,
  unit.names.variable = "state_name"
)
```

Após isso, cria-se a califórnia sintética

```
synth_out <- synth(
  data.prep.obj = dataprep_out
)
```

```
##
## X1, X0, Z1, Z0 all come directly from dataprep object.
##
##
## ****************
##  searching for synthetic control unit
##
##
## ****************
## ****************
## ****************
##
## MSPE (LOSS V): 3.209078
##
## solution.v:
##  0.0005834245 0.003366973 0.03117412 0.01243231 0.4925228 0.3917451 0.06817527
##
## solution.w:
##  1.54275e-05 1.27942e-05 0.1746846 0.06241991 1.58974e-05 1.6702e-05 0.0005198372 5.23691e-05 1.7018
```

Para replicar a tabela 1 do artigo basta rodar o seguinto código

```r
# Criando tabelas de resumo
synth.tables <- synth.tab(dataprep.res = dataprep_out, synth.res = synth_out)

# Replicando a tabela 1 do artigo
synth.tables$tab.pred[1:7,]
```

```
##                        Treated Synthetic Sample Mean
## lnincome                10.077     9.859       9.829
## age15to24                0.174     0.174       0.173
## retprice                89.422    89.318      87.266
## special.beer.1984.1988  24.280    24.095      23.655
## special.cigsale.1975   127.100   126.897     136.932
## special.cigsale.1980   120.200   120.248     138.089
## special.cigsale.1988    90.100    91.432     113.824
```

Pesos por estado na criação da califórnia sintética

A Tabela 2 apresenta os pesos atribuídos a cada estado de controle na construção da Califórnia sintética. Os valores indicam que as tendências de consumo de cigarros na Califórnia antes da aprovação da Proposição 99 são melhor replicadas por uma combinação dos estados Colorado, Connecticut, Montana, Nevada e Utah. Todos os outros estados do grupo de doadores recebem peso zero.

```r
synth.tables$tab.w[1:38, ]
```

```
##    w.weights     unit.names unit.numbers
## 1      0.000        Alabama            1
## 2      0.000       Arkansas            2
## 4      0.175       Colorado            4
## 5      0.062    Connecticut            5
## 6      0.000       Delaware            6
## 7      0.000        Georgia            7
## 8      0.001          Idaho            8
## 9      0.000       Illinois            9
## 10     0.000        Indiana           10
## 11     0.000           Iowa           11
## 12     0.000         Kansas           12
## 13     0.000       Kentucky           13
## 14     0.000      Louisiana           14
## 15     0.000          Maine           15
## 16     0.000      Minnesota           16
## 17     0.000    Mississippi           17
## 18     0.000       Missouri           18
## 19     0.182        Montana           19
## 20     0.000       Nebraska           20
## 21     0.236         Nevada           21
## 22     0.000  New Hampshire           22
## 23     0.000     New Mexico           23
## 24     0.000 North Carolina           24
## 25     0.000   North Dakota           25
## 26     0.000           Ohio           26
## 27     0.000       Oklahoma           27
## 28     0.000   Pennsylvania           28
## 29     0.000   Rhode Island           29
## 30     0.000 South Carolina           30
## 31     0.000   South Dakota           31
```

```
## 32     0.000      Tennessee           32
## 33     0.000          Texas           33
## 34     0.343           Utah           34
## 35     0.000        Vermont           35
## 36     0.000       Virginia           36
## 37     0.000  West Virginia           37
## 38     0.000      Wisconsin           38
## 39     0.000        Wyoming           39
```

Evolução nas vendas per capita de cigarros: Califórnia vs. Califórnia sintética.

A Figura 2 mostra as vendas de cigarros per capita da Califórnia e de sua contraparte sintética no período de 1970 a 2000. Isso sugere que a Califórnia sintética fornece uma aproximação razoável do número de maços de cigarros per capita que teriam sido vendidos na Califórnia entre 1989 e 2000 na ausência da Proposição 99.

```r
path.plot(
  synth.res = synth_out,
  dataprep.res = dataprep_out,
  Ylab = "Cigarros per capita",
  Xlab = "Ano",
  Legend = c("California Real", "California Sintetica"),
  Legend.position = "topright"
)

title("Vendas de Cigarros per Capita: California vs Sintetica")

# Linha vertical tracejada no ano da intervenção
abline(v = 1988, lty = 2, col = "black", lwd = 1.2)
```

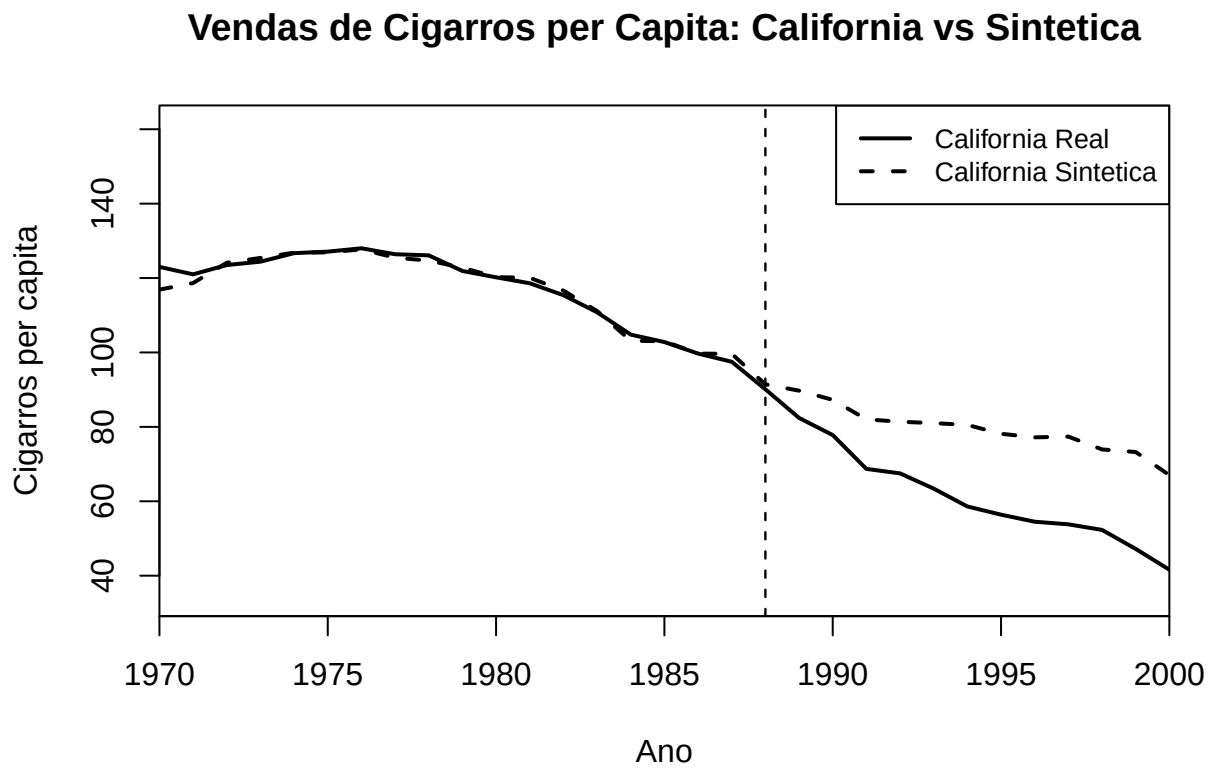

Gap nas vendas per capita de cigarros entre a Califórnia e a Califórnia sintética.

A estimativa do efeito da Proposição 99 sobre o consumo de cigarros na Califórnia é a diferença entre as vendas de cigarros per capita na Califórnia e na sua versão sintética após a aprovação da Proposição 99. A discrepância entre as duas linhas sugere um grande efeito negativo da Proposição 99 sobre as vendas de cigarros per capita.

```
gaps.plot(
  synth.res = synth_out,
  dataprep.res = dataprep_out,
  Ylab = "Diferença na venda per capita de cigarros (em maços)",
  Xlab = "Ano",
  Main = NA
)
```

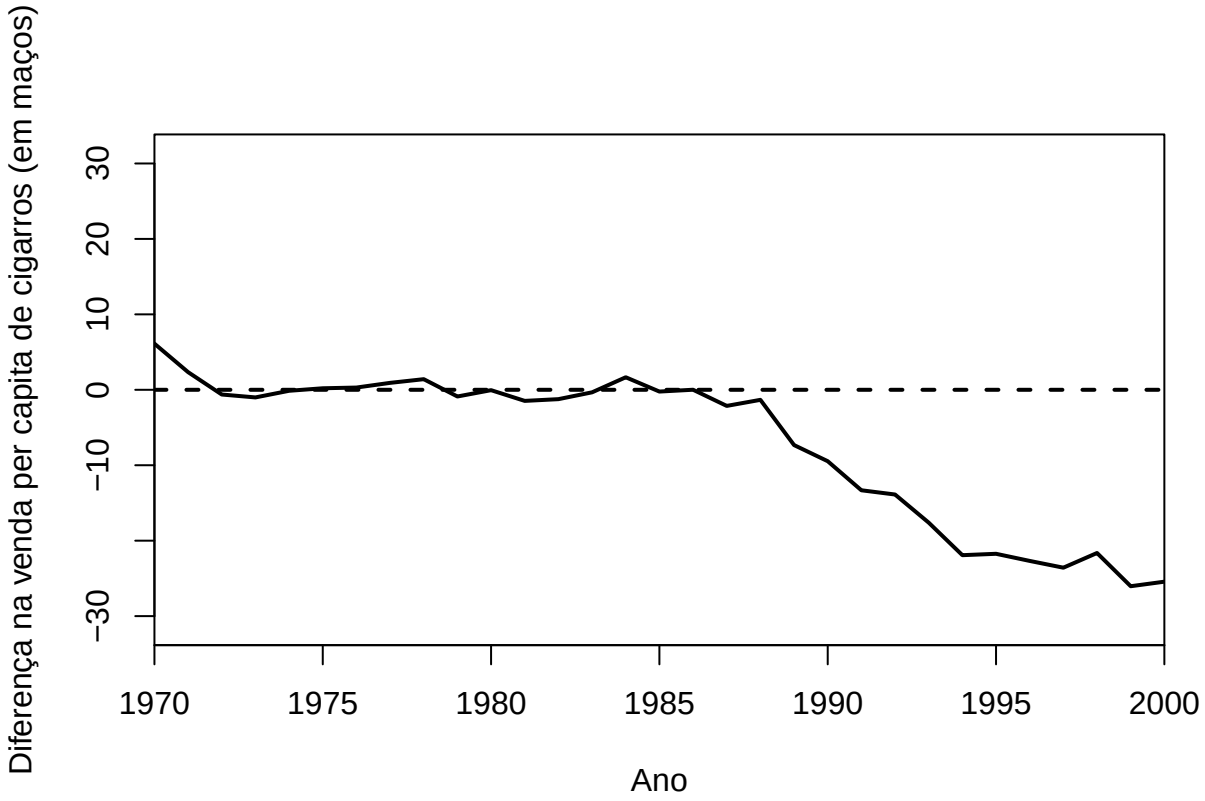

A Figura 3 mostra as estimativas anuais dos impactos da Proposição 99, ou seja, os impactos anuais no consumo de cigarros per capita entre a Califórnia e sua contraparte sintética. A Figura 3 sugere que a Proposição 99 teve um grande efeito sobre as vendas de cigarros per capita, e que esse efeito aumentou ao longo do tempo.

A tabela abaixo, mostra uma estimativa do impacto ano a ano. É estimado uma diminuição de 25,43 maços de cigarro per capita no ano de 2000 dada a proposição aprovada em 1988.

```
# Califórnia real
Y1 <- dataprep_out$Y1plot

# Califórnia sintética
Y0 <- dataprep_out$Y0plot %*% synth_out$solution.w

# Diferença ano a ano (gaps)
gaps <- Y1 - Y0

# Arredondar para duas casas decimais
gaps <- round(gaps, 2)

# Criar data.frame com anos e gaps
gaps_df <- data.frame(
  Ano = dataprep_out$tag$time.plot,
  Gap = gaps
)

gaps_df
```

```
##       Ano     X3
## 1970 1970   6.11
## 1971 1971   2.34
## 1972 1972  -0.63
## 1973 1973  -1.01
## 1974 1974  -0.13
## 1975 1975   0.20
## 1976 1976   0.30
## 1977 1977   0.92
## 1978 1978   1.41
## 1979 1979  -0.89
## 1980 1980  -0.05
## 1981 1981  -1.47
## 1982 1982  -1.24
## 1983 1983  -0.34
## 1984 1984   1.66
## 1985 1985  -0.23
## 1986 1986   0.01
## 1987 1987  -2.13
## 1988 1988  -1.33
## 1989 1989  -7.33
## 1990 1990  -9.47
## 1991 1991 -13.32
## 1992 1992 -13.88
## 1993 1993 -17.61
## 1994 1994 -21.92
## 1995 1995 -21.74
## 1996 1996 -22.68
## 1997 1997 -23.58
## 1998 1998 -21.63
## 1999 1999 -26.04
## 2000 2000 -25.43
```

Gap nas vendas de cigarros per capita na Califórnia e gaps placebos nos 38 estados de controle.

A Figura 4 apresenta os resultados do teste de placebo. As linhas cinzas indicam o desvio observado em cada uma das 38 execuções do teste, ou seja, a diferença nas vendas per capita de cigarros entre cada estado do grupo de doadores e sua versão sintética correspondente. A linha vermelha, sobreposta às demais, mostra o desvio estimado para a Califórnia. Como pode ser visto, o desvio da Califórnia no período de 1989 a 2000 é consideravelmente maior em comparação à distribuição dos desvios observados para os demais estados do grupo de doadores.

```r
# Lista de todos os estados
estados <- unique(df$state_name)

# Vetor para armazenar resultados
placebo_results <- list()

for (estado in estados) {
  # Pular a Califórnia
  if (estado == "California") next

  # Preparar os dados para o estado placebo
  dataprep_placebo <- dataprep(
    foo = df,
```

```r
    predictors = c("lnincome", "age15to24", "retprice"),
    special.predictors = list(
      list("beer", 1984:1988, c("mean")),
      list("cigsale", 1975, c("mean")),
      list("cigsale", 1980, c("mean")),
      list("cigsale", 1988, c("mean"))
    ),
    dependent = "cigsale",
    unit.variable = "state",
    time.variable = "year",
    treatment.identifier = estado,
    controls.identifier = unique(df$state_name[df$state_name != estado]),
    time.predictors.prior = 1980:1988,
    time.optimize.ssr = 1970:1988,
    time.plot = 1970:2000,
    unit.names.variable = "state_name"
  )

  # Rodar o synth
  synth_placebo <- synth(dataprep_placebo)

  # Calcular gaps
  Y1 <- dataprep_placebo$Y1plot
  Y0 <- dataprep_placebo$Y0plot %*% synth_placebo$solution.w
  gaps <- Y1 - Y0

  # Salvar
  placebo_results[[estado]] <- gaps
}
```

```r
# Gaps da Califórnia
Y1_ca <- dataprep_out$Y1plot
Y0_ca <- dataprep_out$Y0plot %*% synth_out$solution.w
gaps_ca <- Y1_ca - Y0_ca

# Plot
plot(dataprep_out$tag$time.plot, gaps_ca, type = "l", lwd = 2, col = "red",
     ylab = "Diferença per capita de cigarros", xlab = "Ano")
abline(v = 1988, lty = 2)

# Adicionar placebos
for (estado in names(placebo_results)) {
  lines(dataprep_out$tag$time.plot, placebo_results[[estado]], col = "gray", lty = 2)
}

legend("topright", legend = c("California", "Placebos"), col = c("red", "gray"), lwd = 2)
```

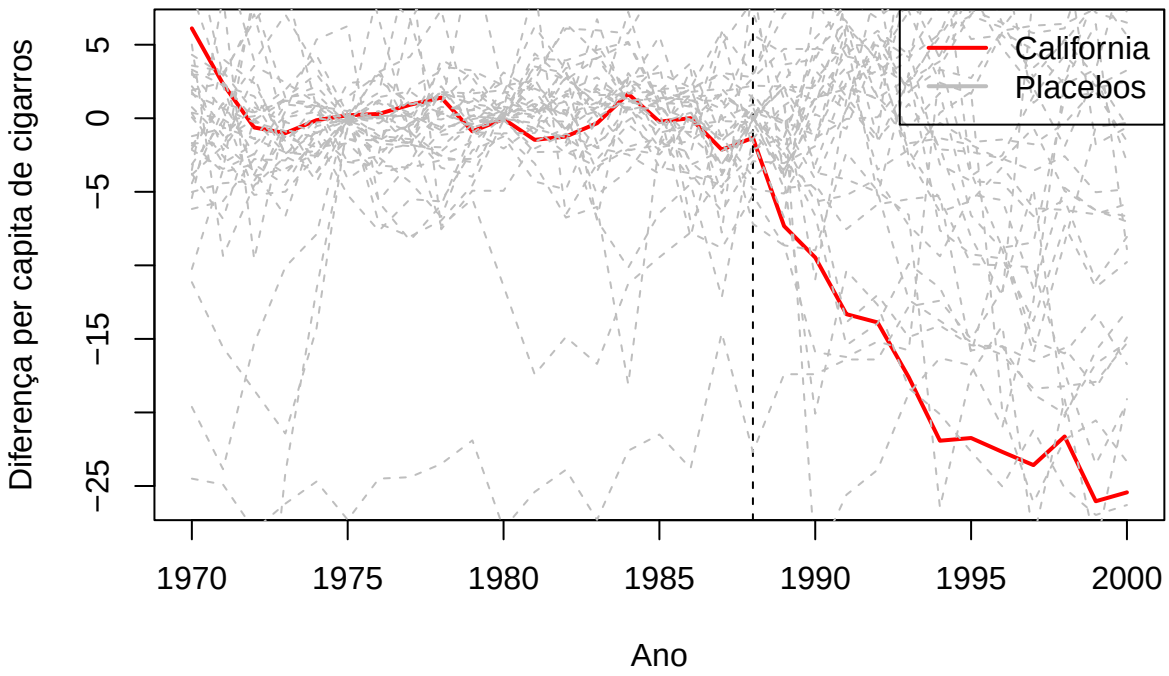

Razão entre o MSPE pós-Proposição 99 e o MSPE pré-Proposição 99: Califórnia e 38 estados de controle.

```
# Função auxiliar para calcular o MSPE ratio de um estado
calc_mspe_ratio <- function(dataprep_res, synth_res, treat.year = 1989) {
  # Valores observados e sintéticos
  Y1 <- dataprep_res$Y1plot
  Y0 <- dataprep_res$Y0plot %*% synth_res$solution.w
  time <- dataprep_res$tag$time.plot

  # Gaps
  gaps <- Y1 - Y0

  # Erro quadrático médio pré e pós
  pre_idx <- which(time < treat.year)
  post_idx <- which(time >= treat.year)

  mspe_pre <- mean(gaps[pre_idx]^2)
  mspe_post <- mean(gaps[post_idx]^2)

  ratio <- mspe_post / mspe_pre
  return(ratio)
}
```

```
ratios <- list()
```

```r
# Califórnia
ratios[["California"]] <- calc_mspe_ratio(dataprep_out, synth_out, treat.year = 1989)

# Placebos
for (estado in estados) {
  if (estado == "California") next

  dataprep_placebo <- dataprep(
    foo = df,
    predictors = c("lnincome", "age15to24", "retprice"),
    special.predictors = list(
      list("beer", 1984:1988, c("mean")),
      list("cigsale", 1975, c("mean")),
      list("cigsale", 1980, c("mean")),
      list("cigsale", 1988, c("mean"))
    ),
    dependent = "cigsale",
    unit.variable = "state",
    time.variable = "year",
    treatment.identifier = estado,
    controls.identifier = setdiff(unique(df$state_name), estado),
    time.predictors.prior = 1980:1988,
    time.optimize.ssr = 1970:1988,
    time.plot = 1970:2000,
    unit.names.variable = "state_name"
  )

  synth_placebo <- synth(dataprep_placebo)
  ratios[[estado]] <- calc_mspe_ratio(dataprep_placebo, synth_placebo, treat.year = 1989)
}
```

```r
ratios_vec <- unlist(ratios)

barplot(ratios_vec,
        names.arg = names(ratios_vec),
        las = 2, cex.names = 0.7,
        col = ifelse(names(ratios_vec) == "California", "red", "gray"),
        ylab = "MSPE pós / MSPE pré",
        main = "MSPE Ratios: California vs Placebos")
```

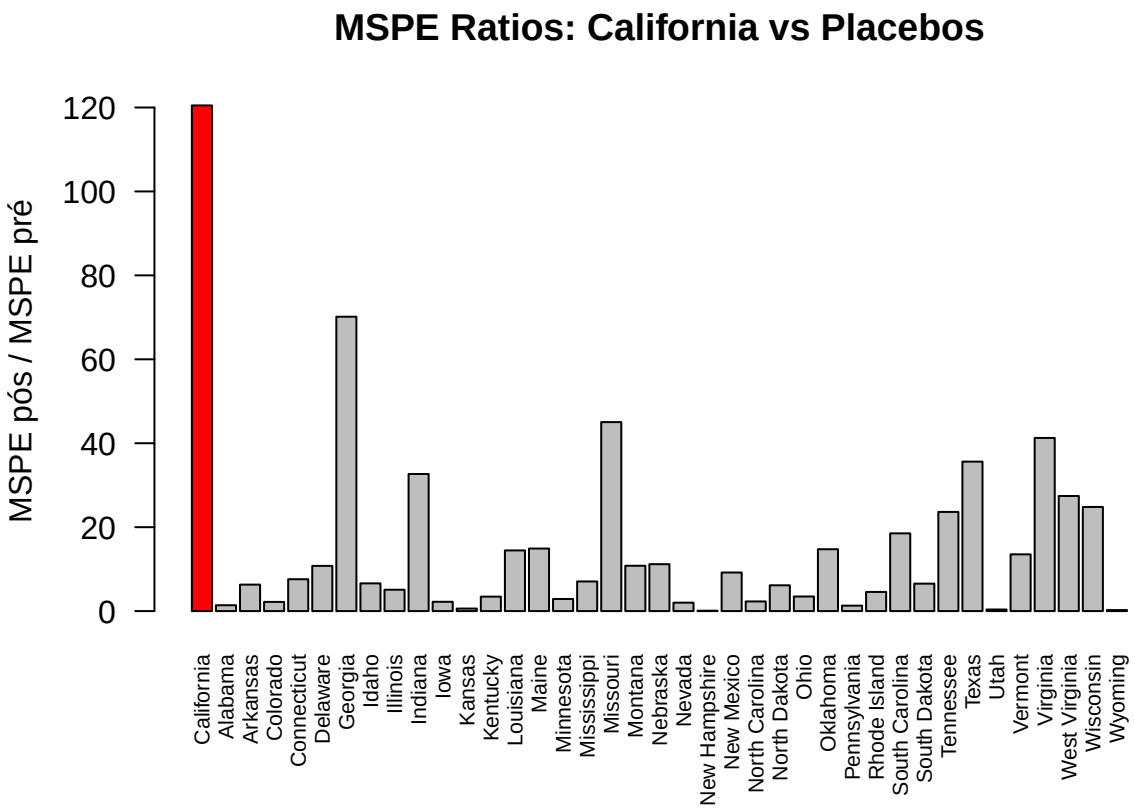
MSPE Ratios: California vs Placebos
MSPE pós / MSPE pré
0
20
40
60
80
100
120
California
Alabama
Arkansas
Colorado
Connecticut
Delaware
Georgia
Idaho
Illinois
Indiana
Iowa
Kansas
Kentucky
Louisiana
Maine
Minnesota
Mississippi
Missouri
Montana
Nebraska
Nevada
New Hampshire
New Mexico
North Carolina
North Dakota
Ohio
Oklahoma
Pennsylvania
Rhode Island
South Carolina
South Dakota
Tennessee
Texas
Utah
Vermont
Virginia
West Virginia
Wisconsin
Wyoming